

# 多層感知網路 (MULTILAYER PERCEPTRON NEURAL NETWORK)

王豐緒

銘傳大學資工系


# 學習目標

- 理解MLP類神經模型的架構
- 理解通用逼近定理
- 理解MLP類神經應用的議題
  - 權重設定初值
  - 激活函數的選擇
  - 避免過度學習
- 熟悉MLP應用範例

# 大綱

- 多層感知神經網路的架構
- 網路的前向運算程序
- 通用逼近定理
- 類神經網路應用實務建議與議題
- MLP類神經網路應用

# THE PERCEPTRON (複習)




$$z = wx_0 - \theta$$


$$y = \begin{cases} 1 & \text{if } z > 0 \\ 0 & \text{else} \end{cases}$$

當  $x_0=0.5$  , true vale=1

當  $x_0=-0.5$  , true vale=0





# THE PERCEPTRON (複習)




我們應該選擇另一種激活函數！

# 激活函數的選擇




$$g(h) = \frac{1}{1 + e^{-\beta h}}$$

# 多層感知神經網路的架構



中間隱藏層的神經元激活函數採用**Relu**函數，  
輸出端的神經元的激活函數則是問題而定！




神經元的淨輸入 $z_j^l$  變成:

$$z_j^l = \sum_i w_{ji}^l \times x_i - \theta_j^l$$



## 資料轉換的示例圖



有助於分類



# 網路的前向運算程序

具有一層隱藏層的神經網路，假設輸入層有 3 個節點，輸入數據  $X$  中有 3 筆數據，其標籤為  $y$ ，隱藏層有 2 個節點，隱藏層權重矩陣為  $W1$ ，線性組合  $Z$  等於  $X \cdot W1$ ，經過激活函數  $Relu$  的值令為  $L = Relu(Z)$ ，輸出層有 1 個節點，權重矩陣為  $W2$ ，線性輸出  $O$  等於  $L \cdot W2$


$$X^T = \begin{bmatrix} 1 & 2 & -1 \\ 2 & -3 & 2 \\ -1 & -1 & 3 \end{bmatrix}, y = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}$$

$$W1 = \begin{bmatrix} -1 & 2 \\ 1 & 1 \\ 1 & -1 \end{bmatrix}, W2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$


$$Z = X^T \cdot W1 = \begin{bmatrix} 0 & 5 \\ -3 & -1 \\ 3 & -6 \end{bmatrix}$$

$$L = Relu(Z) = \begin{bmatrix} 0 & 5 \\ 0 & 0 \\ 3 & 0 \end{bmatrix}$$

$$O = L \cdot W2 = \begin{bmatrix} -5 \\ 0 \\ 3 \end{bmatrix}$$



# 範例：解 XOR問題的MLP類神經網路




A	B	E
0	0	0
0	1	1
1	0	1
1	1	0

# 範例：解 XOR問題的PERCEPTRON 類神經網路

```
# Create a Sequential model
# Construct an instance of CustomModel
inputs = Input(shape=(2,))
outputs = Dense(1, activation =
custom_activation )(inputs)
model = CustomModel(inputs, outputs)

model.compile( loss="mse", metrics=["mse"] )
#XOR Problem
trainin=np.array([[0.0, 0.0], [0.0, 1.0],[1.0,
0.0],[1.0, 1.0]])
traintgt=np.array([[0.0], [1.0],[1.0],[0.0]])


history= model.fit(x=trainin, y=traintgt,
epochs=1000, verbose=2)
```



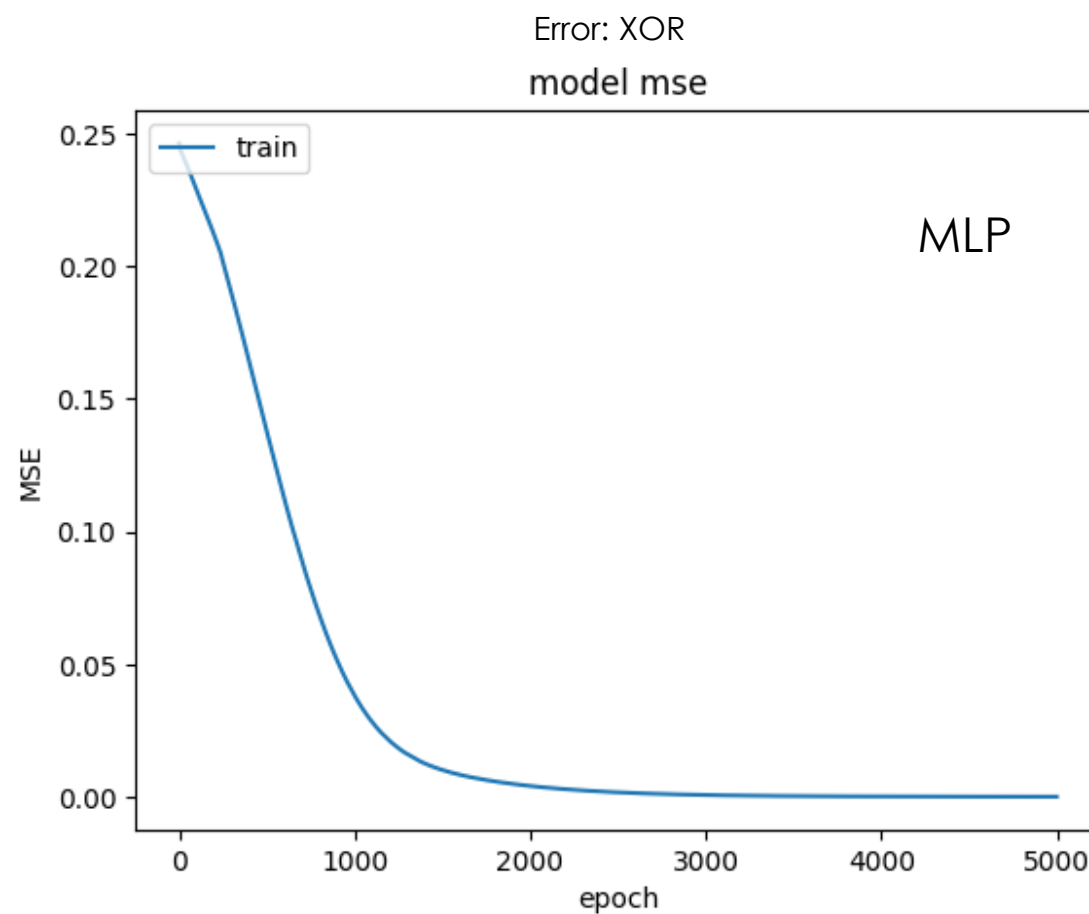
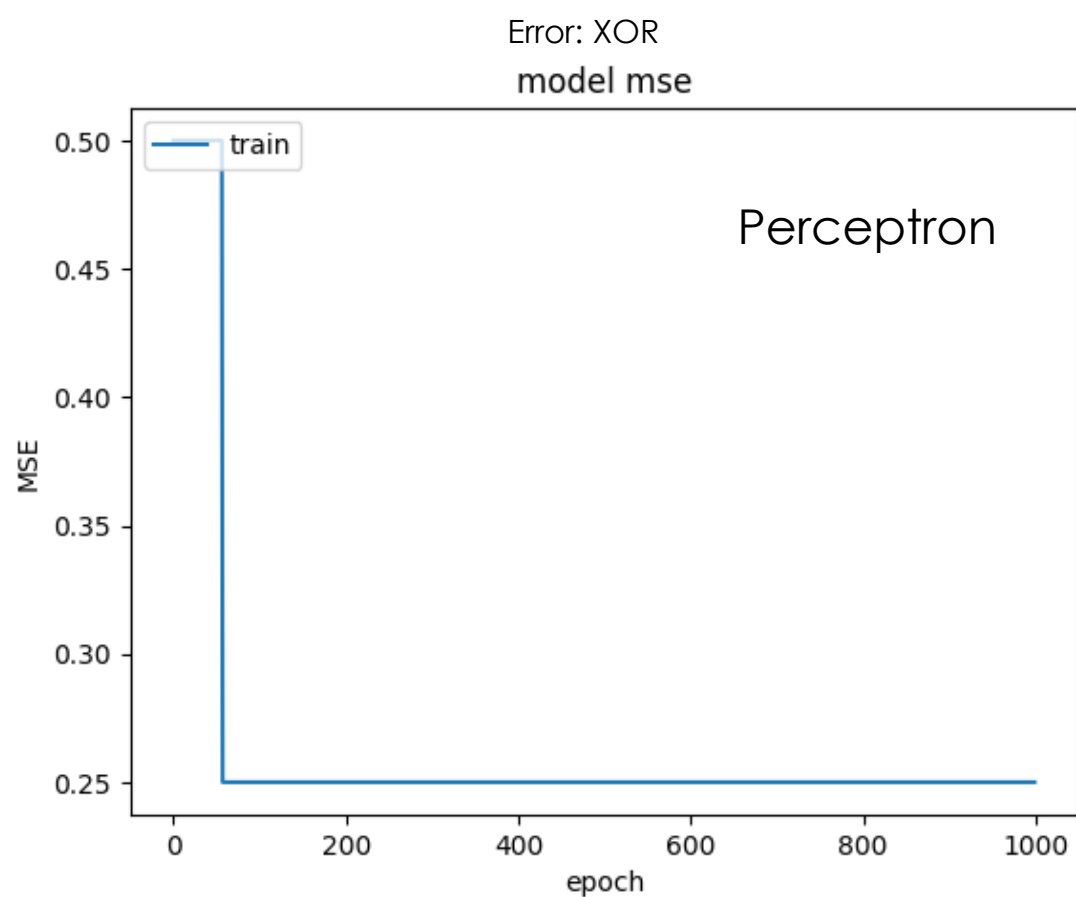
# 範例：解 XOR問題的MLP類神經網路

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Input
from tensorflow.keras import Model
import numpy as np
# Create a Sequential model
# Construct an instance of CustomModel
inputs = Input(shape=(2,))
hidden=Dense(10, activation = 'relu')(inputs)
outputs = Dense(1, activation = 'sigmoid')(hidden)
model = Model(inputs, outputs)

model.compile( loss="mse", metrics=["mse"] )
#XOR Problem
trainin=np.array([[0.0, 0.0], [0.0, 1.0],[1.0,
0.0],[1.0, 1.0]])
traintgt=np.array([[0.0], [1.0],[1.0],[0.0]])
history= model.fit(x=trainin, y=traintgt,
epochs=1000, verbose=2)
```





# PERCEPTRON 與 MLP 訓練結果





# 範例：辨識阿拉伯數字的MLP網路

- 辨識手寫阿拉伯數字的神經網路 (MNIST database)
  - 訓練資料包含  $28 \times 28$  (**=784**) 像素的手寫阿拉伯數字灰階影像
  - 輸出層包含**10**個神經元，分別代表 0~9
  - 均方差損失函數  $C_{w,b}(x) = \frac{1}{2} \times \|(y(x) - \hat{y})^2\|$ 
    - 均方差 (**Mean Squared Error, MSE**)
    - $y(x)$ : 對應  $x$  的真實答案
    - $\hat{y}$ : 網路預測的輸出答案
    - $w$ : 網路權重參數
    - $b$ : 網路的偏值(bias)參數




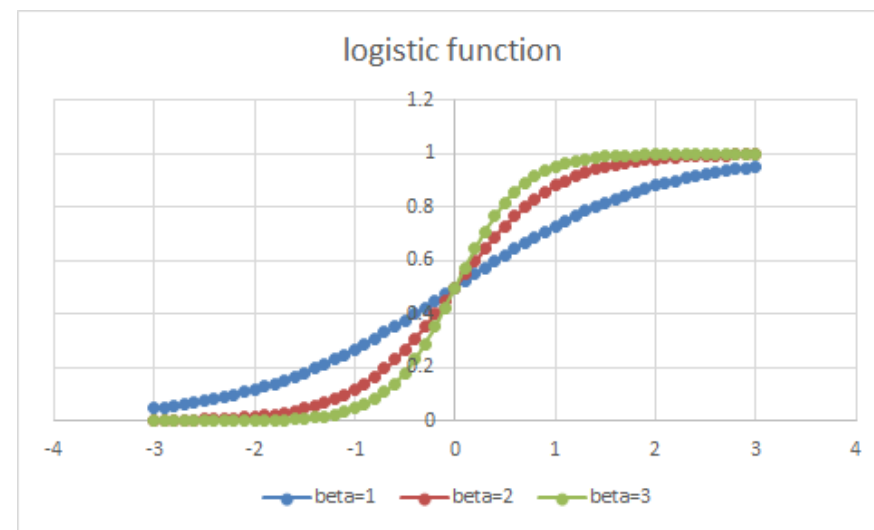


# 通用逼近定理(UNIVERSAL APPROXIMATION THEOREM)

- 包含有限數量神經元的**單一隱藏層**的多層感知器前饋網路可以在激活函數的溫和假設下近似  $R^n$  的緊湊子集上的連續函數
- 該定理指出當給定適當的參數時，簡單的神經網路可以表示各種有趣的函數（任何平滑映射）
- 然而，它並沒有涉及這些參數的演算法可學習性


# 實務建議與議題(1)

- 權重參數的初始化
  - 假設有  $n$  連結至一個神經元, 其權重的初值可隨機設為  $\frac{-1}{\sqrt{n}} < w < \frac{1}{\sqrt{n}}$ , 並使其總和為1
- 激活函數
  - 選用 **logistic (sigmoid)** 函數時, 可使用  $\beta \leq 3$  (不要太陡峭)
  - 對於**回歸 (regression)** 問題, 輸出層的神經元可選用 **linear** 函數:  $g(h) = h$
  - 對於**分類 (classification)** 問題
    - 二元分類, 輸出層的神經元們可選用 **sigmoid** 函數
    - 多元分類, 輸出層的神經元們可選用 **soft-max** 函數:  $g(h_k) = \frac{e^{h_k}}{\sum_j e^{h_j}}$



## 實務建議與議題(2)

- 何時停止學習?
  - 欠擬合(Under-fitting)
    - 網路沒有學習到訓練資料的正確分佈
  - 過擬合 (Over-fitting)
    - 網路開始學習訓練資料中的雜訊
  - 使用驗證資料集 (validation data set) 檢查停止點

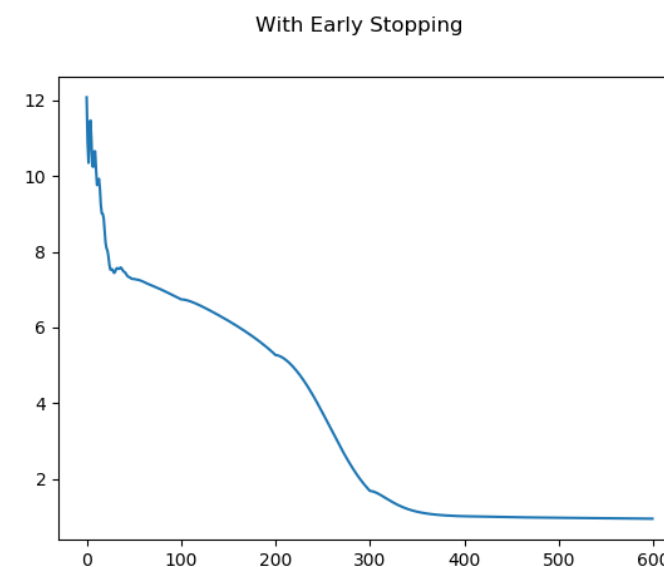




# MLP的應用

- 回歸 (Regression) 問題
- 分類 (Classification) 問題
- 時間序列預測 (Time-series Prediction)
- 資料壓縮與編碼 (Data compression/encoding)

# 回歸 (REGRESSION) 問題


- Sinewave 回歸案例
  - 輸出層神經元激活函數: **linear**
  - 包含 訓練, 驗證, 與測試資料集



# 分類 (CLASSIFICATION) 問題

- Iris 資料集
  - 每個類別先做 **one-hot-encoding**
    - 4個實數形輸入值
    - 3種鳥類
  - 輸出端神經元採用 **soft-max** 激活函數
    - 所有輸出值總和為1
    - 挑選輸出值最大者作為預測類別

1. sepal length in cm	5.1,3.5,1.4,0.2,0
2. sepal width in cm	4.9,3.0,1.4,0.2,0
3. petal length in cm	4.7,3.2,1.3,0.2,0
4. petal width in cm	6.7,3.1,4.4,1.4,1
5. class:	5.6,3.0,4.5,1.5,1
-- Iris Setosa	5.8,2.7,4.1,1.0,1
-- Iris Versicolour	6.2,2.2,4.5,1.5,2
-- Iris Virginica	5.6,2.5,3.9,1.1,2
	5.9,3.2,4.8,1.8,2





# 時間序列預測

- 給定資料:  $x(1), x(2), x(3), \dots$ , 學習下列函數:
  - $y = x(t + \tau) = f(x(t), x(t - \tau), \dots, x(t - k\tau))$
  - $\tau$ : 時間間隔
  - $k$ : 參考資料個數


例如, 給定  $\tau=2, k=3$

則:

$x(1), x(3), x(5) \Rightarrow x(7) = ?$



$x(2), x(4), x(6) \Rightarrow x(8) = ?$

....



# 時間序列預測

- 資料集: PNOZ.dat
  - 2855 筆資料
  - 4個變數, 但本例子只使用第3個: 臭氧層的厚度
  - 輸出端神經元使用 **linear** 激活函數
  - 使用最後400筆資料做測試†
  - 給定  $\tau=2$ ,  $k=3$ ,
    - 有3個輸入, 1個輸出





# 資料壓縮/編碼

- 自我編碼器

- 訓練網路可以重製輸入資料

- 應用

- 壓縮
    - 2D 影像 to 1D 向量特徵
  - 解碼
    - 儲存第二層權重 $W$ 的集合
    - 從特徵回復原始圖片



# 小結

- MLP類神經模型可以解決非線性可分問題
- 通用逼近定理
- 一些實際問題
  - 權重設定初值
  - 激活函數的選擇
  - 儘早停止學習
- 各種MLP應用練習

# REFERENCE

- Online Book
  - <http://neuralnetworksanddeeplearning.com/chap2.html>

Q&A